

基于前景感知局部聚合与时序自适应融合的 BEVFormer 多视角三维目标检测

顾清华^{1,2,3}, 邱鑫^{1,3}, 李少博^{3,4}

(1. 西安建筑科技大学人工智能与机器人学院, 西安 710055; 2. 西安建筑科技大学资源工程学院, 西安 710055; 3. 西安建筑科技大学西安市智慧工业感知计算与决策重点实验室, 西安 710055; 4. 西安建筑科技大学管理学院, 西安 710055)

摘要: 针对 BEVFormer 模型多视角三维目标检测中局部鸟瞰图上下文利用不充分、时序特征融合自适应能力不足的问题, 提出一种结合前景感知局部聚合与时序自适应融合的多视角三维目标检测方法。首先, 设计前景感知局部聚合模块 (Foreground-Aware Local Aggregation, FALA), 根据各 BEV 网格的前景置信度选择性聚合高价值区域的邻域信息, 并通过门控更新抑制背景冗余, 增强目标区域的局部空间结构表征。其次, 设计时序自适应融合模块 (Temporal Adaptive Fusion Module, TAF), 利用当前与历史 BEV 特征的差异生成位置相关的融合权重, 动态调节两类特征的贡献, 提高时序信息利用效率和运动状态估计能力。在 nuScenes 验证集上, 采用 BEVFormer-Small 配置时, 本文方法的 mAP 和 NDS 分别达到 0.402 和 0.506, 较基线分别提升 1.3 和 1.9 个百分点。消融实验表明, FALA 能够有效改善目标定位与方向估计, TAF 有助于降低速度估计误差, 联合使用两个模块时获得最高的 mAP。实验结果验证了所提方法在增强前景空间表征和时序运动建模方面的有效性。

关键词: 三维目标检测; 鸟瞰视角; 多视角图像; 时序特征融合; BEVFormer

引言

环境感知作为自动驾驶系统实现精准决策、安全行车的核心基础, 感知精度与场景适应性直接决定自动驾驶功能的可靠性与稳定性。现阶段自动驾驶三维感知技术体系日趋完善, 主流感知方法可分为单视角图像感知、多传感器融合感知与鸟瞰视角 (Bird's Eye View, BEV) 感知三类。其中, 传统单视角图像感知如 YOLO^[1]系列仅依托单一相机获取场景信息, 存在视角局限、空间位置建模不准、跨场景泛化性差等问题, 难以精准刻画复杂路况下目标物体的三维空间关系, 无法满足高阶自动驾驶的安全感知需求。为弥补单目感知的缺陷, 多传感器融合感知技术被广泛研究, 通过融合相机、激光雷达、毫米波雷达等多源传感器数据, 结合不同传感器的感知优势互补, 有效提升了场景感知的完整性与鲁棒性^[2]。但该方案存在传感器标定难度大、数据时序对齐复杂、硬件成本高、系统冗余度大等现实问题, 不利于自动驾驶感知系统的轻量化、规模化落地。

相较于上述两类方法, BEV 感知能够将多视角二维图像特征统一映射至俯视鸟瞰空间, 构建全局统一、逻辑清晰、可解释性强的三维场景表征, 摆脱了单视角感知的空间约束, 同时规避了多传感器融合的硬件与算法冗余问题, 凭借简洁高效、空间建模精准的核心优势, 已成为新一代自动驾驶感知体系的主流发展方向, 被广泛应用于多视角三维目标检测、场景分割等核心感知任务中。现有 BEV 方法主要分为两类, 一类是基于 LSS (Lift-Splat-Shoot)^[3]的显式监督方法, 另一类是基于注意力机制的 Transformer^[4]隐式监督方法。前者基于 LSS 的经典算法如 BEVDet^[5]率先将 LSS 操作整合进端到端检测流程, 结合视锥特征构建与 BEV 池化技术, 完成多视角图像到鸟瞰图特征的有效转换, 在此基础上开展三维目标检测, 证实了该技术路径在自动驾驶场景的实际可行性。BEVDepth^[6]采用显式深度监督策略, 有效提升了复杂地形下的检测精度。多相机间特征关联计算开销较大, BEVStereo^[7]引入动态时序匹配与参数演化机制应对该问题。FB-BEV^[8]则从视图转换角度设计前向-后向联合投影方法, 通过双向特征传播进一步提升深度分布估计的准确性。

基于 Transformer 的各类方法中, Zhiqi Li 等人 2022 年提出的 BEVFormer 是代表性成果。该工作以 DETR3D^[9]、Deformable DETR^[10]等前期研究为基础, 将 Transformer 架构用于多视角三维目标检测, 搭建了统一的鸟瞰视角特征表示框架。BEVFormer 以可学习的 BEV query 为场景表征载体, 通过空间交叉注意力机制从多视角图像特征中提取 BEV 网格对应信息, 再经时间自注意力融合历史时刻 BEV 特征, 完成时空信息统一建模。其端到端建模方式具备较强的时空特征提取能力, 在 nuScenes 等标准数据集上表现突

出，是后续多视角 BEV 感知研究的核心基准方法。

BEVFormer 在多视角到 BEV 表征转换中效果较好，但性能仍受 BEV 特征表达能力制约。现有改进主要沿两个方向推进。一是优化图像到 BEV 的特征采样与映射方式，提升跨视角信息聚合准确性，代表工作包括 WidthFormer^[11]、LHFormer^[12]、DenseBEV^[13]等。二是强化 BEV 空间结构或时序信息建模，改善复杂场景下的目标表征质量，这类改进模型代表作有 PETR^[14]、HV-BEV^[15]。但这类主流 BEVFormer 框架在复杂动态场景下，其 BEV 局部空间建模与时序特征自适应利用方面仍存在进一步优化空间。同时随着对 BEVFormer 模型结构的更深入的研究，针对 BEVFormer 特征建模与时序表达的不足，通过新增模块、额外监督、先验知识引入与结构微调的方式提升性能。BEVDiffuser^[16] 将扩散模型引入 BEV 特征学习，通过真值布局引导增强 BEV 特征的去噪与表征能力，并可作为即插即用模块提升检测性能。CorrBEV^[17] 引入图像特征、点云特征等多模态原型开展跨模态相关性学习，强化 BEV 特征的原型表示能力，更适配复杂场景下物体共性特征建模。BEVFormer v2^[18] 面向 ConvNeXt^[19]、Swin Transformer^[20] 等现代图像主干网络适配需求，加入透视监督（Perspective Supervision），在图像视角与 BEV 视角间建立直接映射约束，充分释放大容量骨干网络在 BEV 感知任务中的潜力。CLIP-BEVFormer^[21] 尝试引入“真值流”信息优化模型，融入物体运动真实轨迹先验，增强 BEV 特征的时序连贯性与动态目标表征准确性。但这类方法会增加模型参数量与计算开销，对硬件算力与推理资源要求更高，难以在车载相对轻量化部署场景下实现精度与速度的平衡。

相较已有研究，本文重点分析 BEVFormer^[22] 生成鸟瞰图特征后的局限性并做出改进。首先 BEVFormer 原生时序自注意力首先利用可学习的采样偏移和注意力权重分别对历史 BEV 特征与当前 BEV 特征进行时序交互，但在最终输出聚合阶段，对历史分支和当前分支的注意力输出采用固定等权平均方式进行融合。无法依据场景动态变化、网格时空差异自适应权衡历史先验与实时特征的贡献占比。固定权重易引入无效时序噪声，弱化有效特征信息，导致动态目标 BEV 表征稳定性不足、场景泛化能力受限。且 BEVFormer 通过 BEV 查询从多视角图像特征中跨视角采样，为每个网格位置构建对应鸟瞰表示。该方法可完成视角特征到空间特征的转换，但未显式建模 BEV 空间的局部邻域结构。远距离、小目标或遮挡严重场景下，单一 BEV 网格特征易受采样偏差、观测不完整干扰，目标表现稳定性随之下降。直接在全 BEV 网格引入密集邻域交互，会增大计算开销，还可能造成大面积背景区域噪声扩散，有碍轻量化条件下的性能稳健提升。

针对上述问题，本文基于 BEVFormer 框架，做出以下改进。本文的主要贡献如下：

- (1) 前景感知局部聚合模块（FALA）可弥补 BEVFormer 模型的显式局部上下文建模缺陷。该模块先预测 BEV 网格的前景置信度，根据 BEV 网格的前景响应对局部邻域特征进行选择性强化的，同时引入轻量化门控机制抑制背景噪声扩散，可有效提升目标区域的空间表征性能。
- (2) 提出时序自适应融合机制（TAF），摒弃固化的均值融合模式，逐网格动态生成时序融合权重，自适应适配不同场景的时序建模需求，在较小额外参数开销下提升模型动态场景感知鲁棒性。
- (3) 在 nuScenes 基准数据集上进行的充分实验证实，联合使用 FALA 和 TAF 可在平均精度均值(mAP)和归一化检测分数（NDS）上取得稳定提升。所提出的方法优于原始的 BEVFormer 和几种主流的多视图 3D 检测模型，可为自动驾驶三维感知任务提供一种有效的优化方案。

1 本文方法

1.1 BEVFormer 整体框架概述

本研究基于 BEVFormer 架构展开研究，如图 1 所示，BEVFormer 是基于 Transformer 的多视角三维检测方法，核心逻辑是通过一组可学习 BEV 查询，在鸟瞰视角下构建统一场景表征，再依托该表征完成三维目标检测。具体而言，首先利用图像主干网络搭配特征金字塔网络，从六张环视摄像头图像中提取多尺度特征。再以预设 BEV 网格为查询基础，经 Transformer 编码器逐步融合多视角图像信息，得到对应 BEV 特征表示。检测头最终根据生成的 BEV 特征，预测目标类别、位置、尺寸、朝向等三维属性。编码阶段，BEVFormer 核心模块分为两类，空间交叉注意力、时间自注意力。空间交叉注意力依托相机参数建立 BEV 查询与图像空间的对应关系，从多视角图像特征中采样当前 BEV 位置关联的视觉信息，完成图像视角到 BEV 视角的特征变换。时间自注意力引入历史时刻 BEV 表征，经跨帧信息交互强化当前时刻场景理解能力，缓解遮挡、运动模糊、单帧信息不足等问题。




图 1 改进 BEVFormer 的整体框架

Fig.1 Overall architecture of the improved BEVFormer

BEVFormer 在多视角三维目标检测任务中表现出色，但模型架构仍存在改进空间。编码器输出的鸟瞰图特征以背景网格为主，仅少数区域对应目标，现有方法缺少潜在前景区域的明确局部增强策略，关键目标的结构信息提取不充分。时间建模阶段，当前帧与历史帧特征的重要性随场景动态变化，原有融合方式对该差异的捕捉能力不足。针对上述问题，本研究提出前景感知局部聚合模块与时序自适应融合模块，提升鸟瞰图表征精确度，优化跨帧特征融合效果。

1.2 前景感知局部聚合模块（Foreground-Aware Local Aggregation, FALA）




图 2 FALA 模块

Fig.2 FALA module

多视角图像经过视角转换后形成的 BEV 特征中，前景目标通常仅占据少量网格，而道路、建筑物等背景区域占据较大比例。BEVFormer 通过空间交叉注意力实现 BEV 查询与多视角图像特征之间的信息交互，但缺少针对潜在前景区域的显式 BEV 平面局部上下文建模。若对全部 BEV 网格进行无差别的局部特征聚合，不仅容易将冗余背景响应引入目标表征，还会增加额外的计算开销。为此，本文提出前景感知局部聚合模块（Foreground-Aware Local Aggregation, FALA）。该模块利用 BEV 特征中的前景响应定位潜在目标区域，并对其邻域信息进行选择性聚合，从而在抑制背景干扰的同时增强目标的局部结构与语义表征。FALA 的整体结构如图 2 所示，下面将分别介绍前景响应估计和局部特征聚合过程。

该模块先基于当前鸟瞰图特征预测各网格的前景响应强度，再用响应值自适应调整局部邻域聚合结果，强化前景区域，抑制背景干扰。经 BEVFormer 编码器处理得到的鸟瞰图特征表示为 $B \in \mathbb{R}^{(N \times C)}$, $X \in \mathbb{R}^{(C \times H \times W)}$ ，其中 $N = H \times W$ 为 BEV 网格单元数， C 为通道维度。 $X_{i,j}$ 表示位置 (i,j) 处对应的 BEV 特征。

为估计各 BEV 单元的前景响应分数，本文引入轻量级前景评分分支，映射各位置特征，生成前景响应图如式(1)

$$S = \delta(f_{fg}(X)) \quad (1)$$

其中, $f_{fg}(\cdot)$ 表示前景评分函数, 本文采用 1×1 卷积实现, $\delta(\cdot)$ 为 Sigmoid 激活函数, $S \in R^{1 \times H \times W}$ 表示各位置的前景响应分数, 且 $S_{i,j} \in [0,1]$ 。负责显式建模 BEV 空间的前景分布, 较大的响应值表示该位置更可能对应目标前景区域, 有效抑制背景区域的冗余特征干扰。

为实现对 BEV 特征的自适应增强, 本文引入通道门控机制, 由轻量卷积网络实现, 如式(2)

$$G = \delta(f_{gate}(X)) \quad (2)$$

其中, $f_{gate}(\cdot)$ 同样采用轻量映射网络结构实现, 利用 Sigmoid 激活函数 δ 将网络输出映射至 $[0,1]$ 区间, 输出 $G \in R^{C \times H \times W}$ 为多通道门控权重图, 该门控权重后续作用于局部聚合特征, 实现不同通道特征响应强度的自适应调节, 抑制无关通道的干扰信息, 强化目标相关通道的特征贡献。

本文采用深度可分离卷积聚合每个网格的局部邻域特征, 建模 BEV 空间局部结构信息。位置 (i,j) 的局部聚合结果如式(3)

$$L_{i,j} = \sum_{(u,v) \in N(i,j)} W_{u,v} \odot X_{u,v} \quad (3)$$

其中, $N(i,j)$ 表示以 (i,j) 为中心的局部邻域 (3×3 邻域), $W_{u,v}$ 表示为深度可分离卷积中固有的可学习的卷积权重。 $\odot$ 表示逐通道作用。通过该操作, 当前位置能够聚合其邻域内的局部上下文信息, 从而增强局部空间连续性与结构表达。

经过式(3)得到 BEV 网络的局部聚合特征后, 进一步结合门控机制与前景置信度实现对局部特征的自适应增强, 并采用残差结构保障特征传递, 其计算过程如式(4)

$$Y = X + S \odot f_{proj}(f_{agg}(L \odot G)) \quad (4)$$

其中, $L = \{L_{i,j}\}$ 为式(3)输出单网格局部特征 $L_{i,j}$ 全部网格拼接得到的局部上下文特征图。 G 为门控分支输出权重图, 对聚合完成后的特征 L 做逐元素自适应调制, 经过前景感知加权后的局部聚合特征, 使得模型能够将更多注意力集中于潜在目标区域, 而对背景区域仅保留较弱响应, 从而实现前景感知的选择性局部增强。 $f_{agg}(\cdot)$ 完成聚合特征的通道变换、归一化与非线性激活, 前景置信图 S 在残差融合阶段对调制后的特征进一步加权, 实现前景区域增强、背景抑制。 $f_{proj}(\cdot)$ 为输出投影变换函数, 由 1×1 卷积与组归一化 (GroupNorm) 构成, 对经过门控调制后的特征执行通道维度的映射变换与归一化处理, 用于融合调制特征、约束特征分布, 输出与输入通道数一致的特征张量。最后通过残差连接融合前景感知的局部聚合特征与初始鸟瞰图特征, 保留原始鸟瞰图的整体语义信息, 强化局部细节表现, 得到最终输出。

1.3 时序自适应融合模块 (Temporal Adaptive Fusion Module, TAF)




图 3 TAF 模块

Fig.3 TAF module

BEVFormer 原生时序自注意力借助车辆车位姿完成历史 BEV 特征和当前 BEV 空间对齐, 随后对对齐完成的历史与当前 BEV 特征执行全局平均融合。该方式对全部 BEV 网格采用无差别融合策略, 难以适配运动目标、静止遮挡目标以及静态背景的不同时序建模需求。同时未能利用帧间特征差异表征的运动线索, 易受位姿对齐残留噪声的干扰。为此本文提出 TAF 时序自适应融合模块, 实现面向场景内容的自适应时序特征融合。

本研究提出差异感知的时序自适应融合模块 (Temporal Adaptive Fusion Module, TAF), 结构如图 3 所

示。该模块基于已有时序交互结果，引入显式差异建模机制与自适应时序融合策略，强化模型对时序变化区域的表征能力。模块包含四个核心部分：差异信息提取、门控权重生成、自适应时序融合和差异残差补偿。设计兼顾结构轻量化，可依据当前与历史时刻的特征差异，动态调整融合阶段各时刻信息的贡献度。

设当前时刻的 BEV 特征表示为 $B_t \in \mathbb{R}^{N \times C}$ ，历史时刻的 BEV 特征表示为 $B_{t-1} \in \mathbb{R}^{N \times C}$ 其中 N 表示 BEV 查询的数量， C 表示通道维度。首先，模块通过当前特征与历史特征的差分构造显式时序变化信息，如式(5)，

$$G_t = \delta\left(\text{MLP}\left(\left[B_t; B_{t-1}; B_t - B_{t-1}\right]\right)\right) \quad (5)$$

其中，使用 B_t 和 B_{t-1} 的差值描述了相邻时刻在每个 BEV 位置上的特征变化程度。单纯依赖注意力权重隐式建模时序关系不同，该差异表征能够更加直接地反映场景中可能存在的运动目标区域和局部几何变化区域，为后续自适应融合提供依据。得到差异特征后，本研究沿通道维度合并当前特征、历史特征与差异特征，通过轻量级多层感知机生成各位置、各通道的门控权重。其中， $\text{MLP}(\cdot)$ 表示由线性映射与非线性激活构成的门控预测网络， $\delta(\cdot)$ 为 Sigmoid 激活函数，输出门控权重 $G_t \in [0, 1]^{N \times C}$ ，该门控权重能够根据当前与历史特征的一致性和差异性，自适应决定不同时刻特征在各空间位置和通道上的保留比例。

模块依据门控权重，加权融合当前特征与历史特征，得到自适应时序融合结果如式(6)

$$F_t = G_t \odot B_t + (1 - G_t) \odot B_{t-1} + \alpha \cdot \text{Linear}(B_t - B_{t-1}) \quad (6)$$

其中， $\odot$ 表示逐元素乘法。在端到端检测损失的约束下，门控网络能够根据当前特征、对齐后的历史特征及其差异，自适应学习两类特征的贡献比例。理论上，较稳定区域可更多利用历史信息，而变化显著区域可提高当前特征的贡献。

简单门控融合可完成当前与历史特征的权重分配，但可能削弱差异信息在时序表征中的直接作用。本文设计差异残差补偿分支，将显式差异特征映射后补充至融合结果。其中， $\text{Linear}(\cdot)$ 表示线性投影层， α 为可学习标量参数，用于自适应控制差异残差信息的引入强度。该设计能够在仅引入较少额外参数的情况下，将相邻帧之间的变化模式直接注入最终时序表示，从而进一步增强模型对运动目标和边界变化区域的建模能力。

2 实验结果与分析

2.1 数据集介绍

本文在公开自动驾驶多传感器数据集 nuScenes^[23]上完成所提模型的训练与验证。nuScenes 是公开的大规模自动驾驶多模态数据集，采集自新加坡、波士顿等城市的复杂交通场景，共含 1000 段时长 20s 的自动驾驶视频序列，覆盖多类区域、天气与光照条件。采集平台为自动驾驶测试车，搭载 6 个环视相机、1 个 32 线激光雷达、5 个毫米波雷达及高精度 GPS/IMU。相机图像分辨率为 1600×900，采样频率 12Hz。激光雷达采样频率为 20 Hz，水平视场角 360°。数据集内包含完备的传感器内外参、车辆位姿信息。nuScenes 以 2Hz 频率标注关键帧，为车辆、行人、骑行者、交通锥、护栏等多类目标提供高质量 3D 边界框标注，时间维度上保持实例 ID 一致，可支撑 3D 目标检测、多目标跟踪等任务。数据集配套高精度矢量地图，附带场景级天气、能见度等元信息，多样性与挑战性较强。nuScenes 数据集共包含 1000 个场景，按照官方划分，其中 700 个场景用于训练，150 个场景用于验证，150 个场景用于测试。训练集、验证集和测试集分别包含约 28130、6019 和 6008 个标注关键帧。由于测试集标注不公开，本文的消融实验及主要对比实验均在验证集上进行。

2.2 评价指标

本研究采用 nuScenes^[23]官方基准的 3D 目标检测评价体系开展模型性能评估，所用指标包括平均准确率 (mAP)、平均平移误差 (mATE)、平均尺度误差 (mASE)、平均朝向误差 (mAOE)、平均速度误差 (mAVE)、平均属性误差 (mAAE) 及综合指标 nuScenes Detection Score (NDS)。本文以 mAP 和 NDS 为核心评价依据如式(7)和式(8)所示，其余指标作辅助分析。

$$\text{mAP} = \frac{1}{C \cdot |D|} \sum_{c \in C} \sum_{d \in D} \text{AP}_{c,d} \quad (7)$$

其中 C 代表数据集目标类别集合； $|D|$ 为距离阈值的数量； $\text{AP}_{c,d}$ 表示第 c 类目标在距离阈值 d 下的平均精

度，由精确率-召回率（Precision-Recall, PR）曲线下的积分面积求得。mAP 对全部类别与全部距离阈值下的平均精度取算术平均，取值范围为[0,1]，数值越高代表模型检测召回与分类性能越好。

$$NDS = \frac{1}{10} \left[5 \cdot mAP + \sum_{k \in \{ATE, ASE, AOE, AVE, AAE\}} (1 - \min(1, mTP_k)) \right] \quad (8)$$

其中，mATE 为平均平移误差，表征预测框与真值框的中心平移偏差，mASE 为平均尺度误差，反映目标尺寸预测偏差，mAOE 为平均朝向误差，衡量目标航向角的预测偏差，mAVE 为平均速度误差，代表目标运动速度预测偏差，mAAE 为平均属性误差，表征目标属性分类的误差。mTP_k 为上述各项误差指标。通过 min(1, ·) 对过大误差做截断，避免异常样本过度干扰最终得分；检测项 mAP 权重设置为 5，5 项误差子项权重各为 1，求和后归一化得到 NDS，取值范围[0,1]，分数越高代表模型综合性能越优。

2.3 实验环境

实验在 Linux 操作系统下进行，实验平台配备 NVIDIA GeForce RTX 3090 显卡，每张 GPU 显存为 24GB。实验环境采用 Python 3.8.20、PyTorch 1.9.1，CUDA 运行时版本为 11.1。三维目标检测模型基于 OpenMMLab 框架实现，主要依赖包括 MCV 1.4.0、MMDetection 2.14.0 和 MMDetection3D 0.17.1 版本。两种模型的时序队列长度均设为 3，Transformer 编码器和解码器分别包含 3 层和 6 层，训练统一采用 AdamW 优化器。所有模型均基于官方 BEVFormer 代码及其对应配置进行训练，除根据实验平台调整 GPU 数量和单卡批次大小外，其余模型结构、数据处理流程、优化器及训练策略均保持官方设置。官方配置采用 8 张 GPU，并将单卡批次大小设置为 1，对应的全局批次大小为 8。受硬件条件限制，本实验采用 2 张 GPU 进行分布式训练，其中 BEVFormer-Tiny 的单卡批次大小调整为 4，使其全局批次大小仍为 8，与官方配置保持一致；BEVFormer-Small 受显存容量限制，单卡批次大小设置为 1，对应的全局批次大小为 2。两种模型均训练 24 个周期，随机种子统一设置为 0，并启用确定性计算模式，以提高实验结果的可复现性。

2.4 对比实验与分析

为评估本文提出的轻量级时空协同增强方法有效性，本研究将其与原始 BEVFormer 模型及多种主流方法在不同配置下开展对比实验，进一步考察模型在各类目标上的检测性能差异。本文复现基线与改进模型采用一致的数据预处理、训练策略和测试设置。对于主流方法的横向比较，选取相同相机输入模态和 ResNet-101 骨干网络的公开结果，以尽量减小实验配置差异。相关实验结果分别列于表 1（不同模型配置对比）、表 2（各类目标检测性能分析）、表 3（与主流方法对比）。

表 1 不同配置下与基线模型的对比结果

Table 1 Comparison with the baseline under different configurations

Model	Config	Grid Size	Backbone	mAP↑	NDS↑
BEVFormer	Tiny	50×50	ResNet-50	0.260	0.361
Ours	Tiny	50×50	ResNet-50	0.272	0.373
BEVFormer	Small	150×150	ResNet-101	0.389	0.487
Ours	Small	150×150	ResNet-101	0.402	0.506

为公平评价本文方法相对于基线模型的性能提升，在保持输入配置、BEV 网格尺寸和主干网络一致的前提下，分别在 Tiny 和 Small 两种配置上进行对比实验，BEVFormer 还包含计算开销更高的 Base 配置，其训练阶段对 GPU 显存和计算资源要求较高，受现有实验平台硬件条件限制，本文未对 Base 配置进行完整训练。实验结果如表 1 所示。在 Tiny、Small 两种配置下，本文方法相较于原始 BEVFormer 模型有稳步提升。Tiny 配置对应 Grid Size 为 50×50、Backbone 为 ResNet-50，此时本文方法 mAP 从 0.260 升至 0.272，NDS 从 0.361 升至 0.373。Small 配置对应 Grid Size 为 150×150、Backbone 为 ResNet-101，mAP 从 0.389 升至 0.402，NDS 从 0.487 升至 0.506。上述结果表明，所提模块在两种配置下均取得了检测性能增益。其中，Small 配置下的 mAP 和 NDS 分别提升 1.3 和 1.9 个百分点，表明本文方法能够在基线模型的基础上进一步提高检测精度与综合性能。

为进一步分析本文方法对不同类别目标检测性能的影响，表 2 列出了基线模型与本文方法在各类别上的检测结果。斜杠左侧为基线模型的实验结果，右侧为本文方法的实验结果，括号内数值表示本文方法相较于基线模型的性能变化量。其中，traffic cone 类别不参与 AOE、AVE 和 AAE 指标评估，barrier 类别不参与 AVE 和 AAE 指标评估，因此表中对应位置以“-”表示。

从不同类别的检测结果来看，10 类目标中有 8 类的 AP 得到提升，其中 barrier、bicycle 和 motorcycle

的 AP 分别提升 0.036、0.023 和 0.018，提升较为明显。car、truck、bus、construction vehicle 和 traffic cone 等类别也取得了不同程度的改善。在定位及运动状态估计方面，多数类别的 ATE、ASE、AOE、AVE 和 AAE 指标有所下降，例如 motorcycle 的 ATE 和 AVE 分别降低 0.105 和 0.113，truck 的 AVE 降低 0.078，表明改进方法能够在一定程度上改善部分目标的空间定位和运动信息估计。但同时可以看到，部分指标仍存在一定程度的退化，例如 trailer 和 pedestrian 的 AP 分别下降 0.018 和 0.004，construction vehicle 的 ATE 增加 0.147，motorcycle 的 AAE 增加 0.046。总体而言，本文方法在大多数目标类别上获得了性能增益，并提升了整体 mAP 和 NDS，但对于部分困难类别的检测与属性估计仍存在进一步优化空间。

表 2 本文方法（Tiny 版）与基线模型的分类结果对比。斜杠左侧为基线模型结果，右侧为本文改进模型结果，AP 值越大表示检测性能越好，其余指标值越小表示性能越好。表中数值均经四舍五入保留三位小数。

Table 2 Comparison of classification results between the proposed method (Tiny version) and the baseline model. Values on the left of the slash denote the results of the baseline model, and those on the right denote the results of our improved model. A higher AP indicates better detection performance, while smaller values of the remaining metrics correspond to superior performance. All values in the table are rounded to three decimal places.

Object Class	AP↑	ATE↓	ASE↓	AOE↓	AVE↓	AAE↓
car	0.458 / 0.467 (+0.009)	0.665 / 0.649 (-0.016)	0.162 / 0.161 (-0.001)	0.126 / 0.124 (-0.002)	0.529 / 0.529 (0.000)	0.222 / 0.219 (-0.003)
truck	0.195 / 0.208 (+0.013)	0.915 / 0.871 (-0.044)	0.243 / 0.239 (-0.004)	0.214 / 0.193 (-0.021)	0.606 / 0.528 (-0.078)	0.240 / 0.232 (-0.008)
bus	0.273 / 0.286 (+0.013)	0.930 / 0.859 (-0.071)	0.256 / 0.220 (-0.036)	0.147 / 0.135 (-0.012)	1.490 / 1.521 (+0.031)	0.312 / 0.331 (+0.019)
trailer	0.081 / 0.063 (-0.018)	1.156 / 1.155 (-0.001)	0.273 / 0.261 (-0.012)	0.669 / 0.677 (+0.008)	0.427 / 0.433 (+0.006)	0.084 / 0.076 (-0.008)
construction vehicle	0.050 / 0.057 (+0.007)	1.079 / 1.226 (+0.147)	0.486 / 0.496 (+0.010)	1.459 / 1.397 (-0.062)	0.142 / 0.162 (+0.020)	0.356 / 0.376 (+0.020)
pedestrian	0.349 / 0.345 (-0.004)	0.816 / 0.819 (+0.003)	0.304 / 0.308 (+0.004)	0.897 / 0.862 (-0.035)	0.669 / 0.641 (-0.028)	0.269 / 0.261 (-0.008)
motorcycle	0.236 / 0.254 (+0.018)	0.901 / 0.796 (-0.105)	0.277 / 0.276 (-0.001)	0.837 / 0.814 (-0.023)	0.858 / 0.745 (-0.113)	0.256 / 0.302 (+0.046)
bicycle	0.205 / 0.228 (+0.023)	0.822 / 0.768 (-0.054)	0.290 / 0.284 (-0.006)	1.242 / 1.189 (-0.053)	0.350 / 0.338 (-0.012)	0.030 / 0.033 (+0.003)
traffic cone	0.389 / 0.406 (+0.017)	0.786 / 0.800 (+0.014)	0.343 / 0.354 (+0.011)	-	-	-
barrier	0.368 / 0.404 (+0.036)	0.905 / 0.865 (-0.040)	0.303 / 0.302 (-0.001)	0.158 / 0.153 (-0.005)	-	-

表 3 对比了本文方法与当前主流三维目标检测方法的整体性能。为尽量减小不同方法实验配置差异，表 3 选取采用相同相机输入模态和 ResNet-101 骨干网络的公开结果进行横向比较。实验结果表明，Ours (S) 取得了 0.506 的 NDS 和 0.402 的 mAP，整体性能优于 FCOS3D、PGD、DETR3D 和 BEVFormer (S) 等现有方法。与 HV-BEV (S) 相比，Ours (S) 的 NDS 和 mAP 分别提高了 0.004 和 0.003，取得小幅性能增益。在各项误差指标中，本文方法在 mATE、mAOE 和 mAAE 等指标上均表现良好，其中 mAOE 相较于 BEVFormer (S) 由 0.407 降至 0.378。同时，mAAE 的降低也反映出其在目标属性预测方面的优势。且相较于原论文 BEVFormer (S)，本文方法的 NDS 提高了 2.7 个百分点，mAP 提高了 3.2 个百分点，多项误差指标也同步下降。综合来看，本文方法在提升检测精度的同时，有效降低了目标定位、朝向估计和属性预测等方面的误差，体现出较为稳定的综合性能改进。

综合表 1、表 2、表 3 实验结果，本文提出的轻量时空协同增强方法可在不同模型配置下稳定提升检测性能，在多类别目标检测、主流方法对比中均展现出良好的精度提升效果与误差控制能力。TAF 模块与 FALA 模块协同作用，强化了 BEV 特征的空间表达与时序建模能力，模型可更准确感知不同类别目标的空

间位置、运动状态及朝向信息。该方法通用性较强，为多视角三维目标检测任务提供了有效的性能优化路径。

表 3 各模型在 nuScenes 验证集上的 3D 目标检测性能对比，其他模型的结果均引自各自的原始论文。表中带后缀 (S) 代表选用其 Small 版本，BEVFormer (S) 为原文公开结果，与本文实验环境下复现的 BEVFormer-Small 基线结果存在一定差异。

Table 3 Comparison of 3D object detection performance on the nuScenes validation set. Results of the other models are taken from their respective original papers. The suffix (S) denotes the Small version. The BEVFormer (S) result is taken from the original paper and differs slightly from the reproduced baseline under our experimental settings.

Method	Modality	Backbone	NDS↑	mAP↑	mATE↓	mASE↓	mAOE↓	mAVE↓	mAAE↓
FCOS3D ^[24]	C	R101	0.415	0.343	0.725	0.263	0.422	1.292	0.153
PGD ^[25]	C	R101	0.428	0.369	0.683	0.260	0.439	1.268	0.185
DETR3D ^[9]	C	R101	0.425	0.346	0.773	0.268	0.383	0.842	0.216
HV-BEV(S) ^[15]	C	R101	0.502	0.399	0.706	0.279	0.395	0.400	0.203
BEVFormer(S) ^[22]	C	R101	0.479	0.370	0.721	0.279	0.407	0.436	0.220
Ours(S)	C	R101	0.506	0.402	0.691	0.279	0.378	0.408	0.192

2.5 消融实验

为验证时序自适应融合模块 (TAF)、前景感知局部聚合模块 (FALA) 的独立作用及联合使用效果，本研究以 BEVFormer 为基线，在 nuScenes 数据集上开展消融实验。所有实验统一数据预处理流程、训练策略与测试设置，骨干网络配置、优化器参数、迭代次数均保持一致，保证组间对比公平，结果见表 4。

表 4 Tiny 配置下消融实验在验证集上的结果

Table 4 Ablation results on the validation set under the Tiny configuration

TAF	FALA	mAP↑	NDS↑	mATE↓	mASE↓	mAOE↓	mAVE↓	mAAE↓
×	×	0.260	0.361	0.897	0.293	0.639	0.634	0.221
✓	×	0.268	0.371	0.889	0.287	0.638	0.602	0.218
×	✓	0.266	0.373	0.878	0.291	0.606	0.593	0.226
✓	✓	0.272	0.373	0.881	0.290	0.616	0.612	0.229

以无额外模块的基准模型为参照，其平均精度均值 (mAP) 为 0.260，nuScenes 检测分数 (NDS) 为 0.361，所有误差指标数值偏高，可作为后续模块有效性验证的比较基准。仅加入时序自适应融合 (TAF) 模块后，模型整体性能有所提升。mAP 较基准提升 0.8 个百分点。NDS 提高 1.0 个百分点，增至 0.371。各项误差指标均有下降，其中反映动态目标速度估计准确度的平均速度误差 (mAVE) 从 0.634 降至 0.602，改善幅度最大。TAF 模块可根据时序特征动态调整当前帧与历史信息的融合权重，增强模型时序建模鲁棒性，更高效利用历史数据提升运动状态估计准确性，避免固定融合策略导致的信息冗余或缺失。

单独配置前景感知局部聚合模块 (FALA) 时，模型性能仍有稳定提升。其 NDS 指标增加 1.2 个百分点，达到 0.373，是各独立模块中 NDS 提升幅度最大的一组。mAOE 指标从 0.639 降至 0.606，mAVE 指标降到 0.593。结果证实 FALA 模块设计有效。该模块预测 BEV 网格的前景置信度，将特征聚合集中在高价值前景区域，抑制背景噪声扩散，增强目标区域的局部上下文信息表达。表明 FALA 有助于改善局部空间表征及部分定位、朝向和运动相关指标。

整合 TAF 模块与 FALA 模块后，模型的 mAP 从 0.260 提升至 0.272，模型的 NDS 达到 0.373，与单独使用 FALA 时持平，表明该配置下的性能增益主要体现在 mAP 的改善上。FALA 模块从空间维度优化 BEV 特征质量，强化前景区域关注以提升特征判别力，为 TAF 模块的时序融合提供更有效的特征输入。TAF 模块则在时间维度上对空间优化后的特征做自适应融合，进一步提取多帧有效信息，二者从空间、时间维度形成互补，共同提升三维目标检测任务下模型的准确性与鲁棒性。然而，部分误差指标未随模块叠加而持续改善，表明空间增强与时序融合之间仍存在一定的特征耦合问题。此外，为进一步分析所提模块带来的模型复杂度变化，对基线模型与改进模型的参数量进行统计。BEVFormer-Tiny 的参数量约为 33.52 M，加入 FALA 与 TAF 模块后，模型参数量约为 34.53 M，仅增加约 1.01 M，增幅约为 3.0%。其中，TAF 模块新增参数量约为 0.79 M，FALA 模块新增参数量约为 0.22 M。由此可见，所提出的两个模块在带来检测性

能提升的同时，仅引入了较小的额外参数开销，体现出较好的轻量化特性。

2.6 可视化分析



图4 本文方法与原始基线模型可视化对比，从上至下依次为基准模型预测结果、本文改进模型预测结果以及真值（GT）。

蓝色检测框代表行人，橙色检测框代表车辆，红色检测框代表两轮车。

Fig.4 Qualitative comparison between the proposed method and the baseline BEVFormer model. From top to bottom: predictions of the baseline BEVFormer, predictions of the proposed method, and Ground-Truth (GT) annotations. Blue, orange, and red bounding boxes denote pedestrians, vehicles, and two-wheelers, respectively.

为直观比较改进模型与基准模型的检测表现，选取同一场景下的六个相机视角进行可视化分析，如图4所示，图(a)、图(b)和图(c)分别为基线模型、本文方法及真实标注（Ground-Truth, GT）。从整体结果来看，基线模型与本文方法均能够检测出前左视角中的近处车辆，以及后方视角中的部分车辆和行人，预测框与真实标注在图像投影位置上基本对应。在此基础上，本文方法在部分远距离目标上的检测结果有所改善，其中前右视角的差异较为明显，原始 BEVFormer 在该视角中未显示预测框，而本文方法在远处行人及车辆所在区域产生了预测框，与真实标注中的部分目标位置相对应，表明本文方法在该场景下缓解了部分漏检现象，对远距离小目标的检测起到积极作用。同时，前左视角中的车辆检测结果与原始模型保持接近，说明改进后仍保留了对该近处目标的检测能力。不过，与真实标注相比，受限于 BEVFormer-Small 的模型规模和特征表达能力，两种方法在前方视角道路右侧的远距离目标区域仍存在一定漏检。总体而言，该组可视化结果展示了本文方法在部分困难目标上的检测改善，为其有效性提供了定性支持。




图5 本文方法与基线模型在 BEV 视角下的检测结果对比。左图为本文方法(a)，右图为基线模型(b)。绿色检测框表示真值，蓝色检测框表示预测结果。

Fig.5 Comparison of detection results in the BEV view between the proposed method and the baseline model. The left panel shows the proposed method (a), and the right panel shows the baseline model (b). Green bounding boxes denote ground-truth annotations, while blue bounding boxes denote predicted results.

如图5所示，以绿色真值框为参照，本文方法(a)在自车左下方的目标密集区域具有更高的预测框重合度，多个蓝色预测框能够较好地覆盖对应的绿色真值框，其中心位置、尺度及朝向与真值更为接近。相比之下，基线模型(b)在该区域的部分预测框存在较明显的平移偏差和框间重叠，部分目标未能与对应真值框实现良好匹配。在自车周围及前方区域，本文方法的预测结果也与真值框保持了较好的空间一致性。上述现象表明，本文方法能够改善部分目标在 BEV 平面上的空间定位与朝向估计精度。其原因在于，FALA 模块利用前景响应强化目标邻域的局部空间信息，降低背景特征对目标表征的干扰。TAF 模块通过自适应融合当前帧与历史帧特征，为目标定位提供更稳定的时序信息支持。尽管如此，少数远距离或相邻目标的预测框仍与真值存在偏差，说明复杂场景下的目标定位精度仍有进一步提升空间。

3 结束语

针对 BEVFormer 存在局部 BEV 上下文信息利用不足、时序特征融合自适应能力有限的问题，本文在保留 BEVFormer 整体检测框架的基础上，分别从空间和时间两个层面对模型进行改进。空间层面设计前景感知局部聚合模块，通过前景置信度引导高价值区域的局部邻域特征聚合，并利用门控机制抑制背景冗余信息，从而增强目标区域的局部空间结构表征能力，改善目标定位与方向估计性能。时间层面引入时序自适应融合模块，通过建模当前帧与历史 BEV 特征之间的差异动态生成融合权重，自适应调节两类特征的贡献，提高时序信息利用效率和目标运动状态估计能力。nuScenes 数据集上的实验结果表明，所提方法

能够有效提升 BEVFormer 的三维目标检测性能。消融实验进一步验证了两个模块的有效性,联合使用时取得了更高的整体检测精度。本文研究为基于 BEV 表示的多视角三维目标检测中局部空间特征增强与时序特征自适应融合提供了一种可行思路,同时保持了纯视觉 BEV 感知框架,在自动驾驶及其他多相机三维环境感知场景中具有一定的应用参考价值。

本文工作仍存在进一步拓展和优化的空间。当前时序模块主要利用相邻帧信息,后续可引入多帧时序交互机制,以捕获更长时间范围内的目标运动特征。前景感知模块可进一步结合显式监督信号,提高前景区域判定和局部特征聚合的准确性。此外,所提方法还可进一步拓展至多模态 BEV 感知框架,并结合模型轻量化、量化及推理加速等技术降低计算开销,为实际自动驾驶感知系统中的实时部署提供支持。

参考文献

- [1] Redmon J, Divvala S, Girshick R, et al. You Only Look Once: Unified, Real-Time Object Detection[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 779-788.
- [2] 姜彤, 智文虎, 李起栋, 等. 智能传感器在自动驾驶中的应用及发展趋势[J]. 传感器与微系统, 2026, 45(9): 1-6.
- [3] Philion J, Fidler S. Lift, Splat, Shoot: Encoding Images from Arbitrary Camera Rigs by Implicitly Unprojecting to 3D[C]//Vedaldi A, Bischof H, Brox T, et al. Computer Vision – ECCV 2020. Cham: Springer International Publishing, 2020: 194-210.
- [4] Vaswani A, Shazeer N, Parmar N, et al. Attention is All you Need[C]//Advances in Neural Information Processing Systems. Curran Associates, Inc., 2017.
- [5] Huang J J, Huang G, Zhu Z, Ye Y, Du D L. BEVDet: High-performance Multi-camera 3D Object Detection in Bird-Eye-View[EB/OL]. [arXiv:2112.11790](https://arxiv.org/abs/2112.11790), 2021-12-22.
- [6] Li Y, Ge Z, Yu G, et al. BEVDepth: Acquisition of Reliable Depth for Multi-View 3D Object Detection[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2023, 37(2): 1477-1485.
- [7] Li Y, Bao H, Ge Z, et al. BEVStereo: Enhancing Depth Estimation in Multi-View 3D Object Detection with Temporal Stereo[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2023, 37(2): 1486-1494.
- [8] Li Z, Yu Z, Wang W, et al. FB-BEV: BEV Representation from Forward-Backward View Transformations[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 6919-6928.
- [9] Wang Y, Guizilini V C, Zhang T, et al. DETR3D: 3D Object Detection from Multi-view Images via 3D-to-2D Queries[C]//Proceedings of the 5th Conference on Robot Learning. PMLR, 2022: 180-191.
- [10] Zhu X Z, Su W J, Lu L W, Li B, Wang X G, Dai J F. Deformable DETR: Deformable Transformers for End-to-End Object Detection[C]//Proceedings of the International Conference on Learning Representations. Virtual: ICLR, 2021.
- [11] Yang C, Lin T, Huang L, et al. WidthFormer: Toward Efficient Transformer-based BEV View Transformation[C]//2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2024: 8457-8464.
- [12] Zheng R, Gao Y, Ling Q. LHFormer: Laplacian-Guided Dynamic Agent BEV Transformer for Monocular Elevation Estimation[C]//2025 6th International Conference on Artificial Intelligence and Electromechanical Automation (AIEA). 2025: 331-334.
- [13] Dähling M, Krebs S, Zöllner J M. DenseBEV: Transforming BEV Grid Cells into 3D Objects[C]//Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision. 2026: 2370-2379.
- [14] Liu Y, Wang T, Zhang X, et al. PETR: Position Embedding Transformation for Multi-view 3D Object Detection[C]//Avidan S, Brostow G, Cissé M, et al. Computer Vision – ECCV 2022. Cham: Springer Nature Switzerland, 2022: 531-548.
- [15] Wu D, Yang F, Xu B, et al. HV-BEV: Decoupling Horizontal and Vertical Feature Sampling for Multi-View 3D Object Detection[J]. IEEE Transactions on Intelligent Transportation Systems, 2025, 26(11): 18734-18746.
- [16] Ye X, Yaman B, Cheng S, et al. BEVDiffuser: Plug-and-Play Diffusion Model for BEV Denoising with Ground-Truth Guidance[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2025: 1495-1504.

- [17] Xue Z, Guo M, Fan H, et al. CorrBEV: Multi-View 3D Object Detection by Correlation Learning with Multi-modal Prototypes[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2025: 27413-27423.
- [18] Yang C, Chen Y, Tian H, et al. BEVFormer v2: Adapting Modern Image Backbones to Bird's-Eye-View Recognition via Perspective Supervision[C]//2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2023: 17830-17839.
- [19] Liu Z, Mao H, Wu C Y, 等. A ConvNet for the 2020s[C]//2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2022: 11966-11976.
- [20] Liu Z, Lin Y, Cao Y, 等. Swin Transformer: Hierarchical Vision Transformer using Shifted Windows[C]//2021 IEEE/CVF International Conference on Computer Vision (ICCV). 2021: 9992-10002.
- [21] Pan C, Yaman B, Velipasalar S, et al. CLIP-BEVFormer: Enhancing Multi-View Image-Based BEV Detector with Ground Truth Flow[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 15216-15225.
- [22] Li Z, Wang W, Li H, et al. BEVFormer: Learning Bird's-Eye-View Representation From LiDAR-Camera via Spatiotemporal Transformers[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2025, 47(3): 2020-2036.
- [23] Caesar H, Bankiti V, Lang A H, et al. nuScenes: A Multimodal Dataset for Autonomous Driving[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 11618-11628.
- [24] Wang T, Zhu X, Pang J, et al. FCOS3D: Fully Convolutional One-Stage Monocular 3D Object Detection[C]//2021 IEEE/CVF International Conference on Computer Vision Workshops (ICCVW). 2021: 913-922.
- [25] Wang T, Zhu X, Pang J, et al. Probabilistic and Geometric Depth: Detecting Objects in Perspective[C]//Proceedings of the 5th Conference on Robot Learning. PMLR, 2022: 1475-1485.

BEVFormer-Based Multi-View 3D Object Detection with Foreground-Aware Local Aggregation and Temporal Adaptive Fusion

GU Qinghua^{1,2,3}, QIU Xin^{1,3}, LI Shaobo^{3,4}

(1. School of Artificial Intelligence and Robotics, Xi'an University of Architecture and Technology, Xi'an 710055, China; 2. School of Resource Engineering, Xi'an University of Architecture and Technology, Xi'an 710055, China; 3. Xi'an Key Laboratory of Smart Industry Perception Computing and Decision Making, Xi'an University of Architecture and Technology, Xi'an 710055, China; 4. School of Management, Xi'an University of Architecture and Technology, Xi'an 710055, China)

Abstract: To address the insufficient utilization of local bird's-eye view (BEV) contextual information and the limited adaptability of temporal feature fusion in BEVFormer-based multi-view 3D object detection, a multi-view 3D object detection method integrating foreground-aware local aggregation and temporal adaptive fusion is proposed. First, a Foreground-Aware Local Aggregation (FALA) module is designed to selectively aggregate neighborhood information from high-value regions according to the foreground confidence of each BEV grid. A gated update mechanism is further employed to suppress redundant background information and enhance the representation of local spatial structures in object regions. Second, Temporal Adaptive Fusion (TAF) module is introduced to generate position-dependent fusion weights based on the differences between the current and historical BEV features, thereby dynamically adjusting their respective contributions and improving the utilization of temporal information and the estimation of object motion states. Experiments on the nuScenes validation set show that, under the BEVFormer-Small configuration, the proposed method achieves an mAP of 0.402 and an NDS of 0.506, outperforming the baseline by 1.3 and 1.9 percentage points, respectively. Ablation studies demonstrate that FALA effectively improves object localization and orientation estimation, while TAF contributes to reducing velocity estimation errors. The combination of the two modules achieves the highest mAP. These experimental results demonstrate the effectiveness of the proposed method in enhancing foreground spatial representation and temporal motion modeling.

Highlights

1. A lightweight Foreground-Aware Local Aggregation (FALA) module is proposed to explicitly model local BEV context. It leverages BEV-grid foreground confidence to implement selective neighborhood aggregation and gated background suppression, addressing the problem of insufficient local spatial feature utilization in vanilla BEVFormer.
2. A Temporal Adaptive Fusion (TAF) module is designed for adaptive cross-frame feature fusion. By exploiting explicit feature differences between current and historical BEV features to produce spatial-aware fusion weights, it overcomes the drawback of fixed temporal fusion strategy and improves motion-state estimation for moving targets.
3. Extensive experiments on nuScenes benchmark confirm that the joint usage of FALA and TAF achieves prominent gains on mAP and NDS. The proposed approach outperforms the original BEVFormer and several mainstream multi-view 3D detectors, yielding competitive performance for autonomous-driving 3D perception.

Keywords: 3D object detection; bird's-eye view; multi-view images; temporal feature fusion; BEVFormer